Université Paris Cité
M1 Informatique — Bases de données avancées

Projet Partie 1

Modélisation et Forme Normale

Arbres et Espaces Verts de Paris

Auteurs : Jordan Lengrai
Nerval Gbaguidi

Année : 2025–2026

Contents

1 Présentation des données **2**
1.1 Les arbres parisiens (`les-arbres.csv`) . . . 2
1.2 Les espaces verts parisiens (`espaces_verts.csv`) . . . 2

2 Dépendances fonctionnelles identifiées **2**
2.1 Dataset Arbres . . . 2
2.2 Dataset Espaces Verts . . . 3

3 Requêtes de vérification des dépendances fonctionnelles **4**
3.1 A2 : `(idemplacement, lon, lat)` → `adresse` . . . 4
3.2 A3 : `(genre, espece)` → `libellefrancais` . . . 4
3.3 EV2 : `ida3d_enb` → `historique` . . . 4
3.4 EV3 : `id_eqpt` → `id_division, competence` . . . 4

4 Atomisation de l'attribut `geo_shape` — Justification **5**

5 Décomposition en FNBC **5**
5.1 Dataset Arbres . . . 5
5.2 Dataset Espaces Verts — Cas intéressants . . . 6

6 Tables de la décomposition — Clés et DFs locales **7**
6.1 Dataset Arbres . . . 7
6.2 Dataset Espaces Verts . . . 8

7 Anomalies détectées dans les données **9**
7.1 Dataset Arbres . . . 9
7.2 Dataset Espaces Verts . . . 10

8 Requêtes de reconstruction des données initiales **10**
8.1 Reconstruction des arbres . . . 10

9 Couverture minimale **10**
9.1 Dataset Arbres . . . 11
9.2 Dataset Espaces Verts . . . 11

1. Présentation des données

Ce projet porte sur deux jeux de données *open data* de la ville de Paris et voici comment notre comprehension de ces jeux de donnée.

1.1. Les arbres parisiens (`les-arbres.csv`)

Chaque ligne représente un arbre individuel répertorié dans la ville. Les attributs décrivent l'arbre lui-même (genre, espèce, taille, circonférence), son emplacement physique (`idemplacement`, arrondissement, adresse, coordonnées GPS), et quelques données de gestion (domanialité, type d'emplacement, remarquable).

1.2. Les espaces verts parisiens (`espaces_verts.csv`)

Chaque ligne représente un espace vert : un parc, un square, une jardinière, un mail, etc. Les attributs couvrent l'identité de l'espace vert (nom, type, catégorie, adresse), ses données de gestion administrative (équipement, division, atelier horticole, dossier ENB), son historique (année d'ouverture, rénovation, ancien nom), et sa géométrie (`geo_shape` : un polygone JSON décrivant le contour de l'espace vert).

2. Dépendances fonctionnelles identifiées

2.1. Dataset Arbres

Nous avons identifié trois dépendances fonctionnelles non-triviales :

F_{arbres}

A1 : `idbase` → `typeemplacement, domanialite, idemplacement, genre, espece, varieteoucultivar, circonferenceencm, hauteurenm, stadedeveloppement, remarquable, geo_longitude, geo_latitude`

A2 : `(idemplacement, geo_longitude, geo_latitude)` → `arrondissement, complementadresse, adresse`

A3 : `(genre, espece)` → `libellefrancais`

Justification A1. `idbase` est l'identifiant naturel d'un arbre, attribué lors de l'inventaire. Il identifie de façon unique chaque individu. Tous les attributs de l'arbre lui sont donc fonctionnellement déterminés.

Justification A2. Un emplacement précis (code d'emplacement + coordonnées) détermine une adresse unique. Les coordonnées sont nécessaires dans la clé car un même `idemplacement` peut correspondre à des positions différentes.

Justification A3. Biologiquement, chaque couple (genre, espèce) détermine un nom principal. Nous avons détecté **16 violations** dans les données (ex. : *Prunus avium* désigné à la fois « Cerisier à fleurs », « Cerisier à fruits »). Ces violations sont des **anomalies de saisie**, non des contre-exemples réels à la DF.

2.2. Dataset Espaces Verts

F_{ev}

EV1 : `nsq_espace_vert` → `nom_ev, adresse_numero, adresse_complement, adresse_typevoie, adresse_libellevoie, adresse_codepostal, geo_latitude_ev, geo_longitude_ev, site_villes, id_atelier_horticole, id_eqpt, ida3d_enb, categorie, type_ev, id_geom`

EV2 : `ida3d_enb` → `annee_ouverture, annee_renovation, ancien_nom_ev, annee_changement_nom, nb_entites, ouvert_ferme, url_plan, last_edited_user, last_edited_date`

EV3 : `id_eqpt` → `id_division, competence`

EV4 : `id_geom` → `geom_type, poly_area, surface_totale_reelle, surface_horticole, presence_cloture, perimeter`

EV5 : `(id_geom, ordre)` → `longitude, latitude`

Justification EV1. `nsq_espace_vert` est l'identifiant naturel unique de chaque espace vert dans le système de gestion de la ville.

Justification EV2. `ida3d_enb` identifie un dossier dans le système ENB (gestion patrimoniale). Ce dossier peut être partagé entre plusieurs espaces verts. Nous avons détecté **4 violations** sur `url_plan` et `annee_ouverture` — anomalies de données documentées (section 7).

Justification EV3. `id_eqpt` identifie un équipement technique. Initialement, nous supposions qu'il déterminait aussi `site_villes` et `id_atelier_horticole`, mais

les tests ont révélé des violations massives (un équipement peut couvrir jusqu'à 6 sites). La DF a été restreinte à `id_division` et `competence`.

Justification EV4. `id_geom` est un identifiant introduit lors de l'atomisation de `geo_shape` (justifié section 4).

Justification EV5. Après atomisation, chaque point du contour est identifié par `(id_geom, ordre)`.

3. Requêtes de vérification des dépendances fonctionnelles

Les requêtes complètes figurent dans le fichier `verification_df.sql`. Nous présentons ici les cas non-triviaux .

3.1. A2 : (idemplacement, lon, lat) → adresse

Cette DF est non-triviale car idemplacement seul ne suffit pas à déterminer l'adresse — un même code d'emplacement peut apparaître dans des parcs différents avec des positions différentes. En ajoutant les coordonnées, on discrimine suffisamment.

Résultat : 0 violation. La DF est vérifiée dans les données.

3.2. A3 : (genre, espece) → libellefrancais

Cette DF est non-triviale car on pourrait s'attendre à ce que le nom soit libre et non déterminé par la paire. Nos tests montrent 16 violations concentrées sur des espèces à noms multiples (cultivars, variétés commerciales). La DF est sémantiquement valide mais les données contiennent des incohérences de saisie.

3.3. EV2 : ida3d_enb → historique

Plusieurs espaces verts peuvent partager un même dossier ENB (cas de regroupement administratif). Nos tests montrent 3 violations sur `url_plan` et `annee_ouverture`, qui correspondent à des espaces verts partageant un `ida3d_enb` mais ayant des valeurs légèrement différentes — anomalies de saisie.

3.4. EV3 : id_eqpt → id_division, competence

Au départ nous supposions que `id_eqpt` → `site_villes`, `id_atelier_horticole` aussi. Les tests ont révélé des violations massives sur ces deux attributs (jusqu'à 6 sites différents pour un même `id_eqpt`). Nous avons donc restreint la DF à ce qui est effectivement vérifié. 0 violation après correction.

4. Atomisation de l'attribut `geo_shape` — Justification

Dans `espaces_verts.csv`, l'attribut `Geo Shape` contient un objet GeoJSON, par exemple :

Listing 1: Exemple de valeur geo_shape

```
{
  "type": "Polygon",
  "coordinates": [
    [ [2.3392, 48.8600], [2.3393, 48.8594],
      [2.3391, 48.8594], [2.3392, 48.8600] ]
  ]
}
```

Cet attribut est **non-atomique** au sens de la 1NF : une seule valeur encode deux réalités distinctes — le type de géométrie et une liste hiérarchique de coordonnées.

Pour satisfaire la 1NF, nous avons procédé à l'atomisation suivante :

- `geom_type` (TEXT) : extrait via `(json)->'type'`
- Table `Geom_coordonnee` : chaque point du contour extérieur devient une ligne identifiée par `(id_geom, ordre)`

L'introduction de `id_geom` est nécessaire pour deux raisons :

1. La colonne `Geo Shape` brute dépasse limite d'un index PostgreSQL — elle ne peut pas servir de clé.
2. `id_geom` capture la DF EV4 qui constitue une violation FNBC réelle (`id_geom` n'est pas super-clé de `Espace_vert`).

Cette modification et la décomposition en 2 attributs `geo_lat` et `geo_lon` sont les **seules** que nous avons apportée aux attributs originaux.

5. Décomposition en FNBC

5.1. Dataset Arbres

Relation initiale.

`Arbre_plat(idbase, typeemplacement, domanialite, idemplacement, genre, espece, varieteoucultivar, circonferenceencm, hauteurenm, stadedeveloppement, remarquable, geo_longitude, geo_latitude, arrondissement, complementadresse, adresse, libellefrancais)`

Clé candidate : `idbase`

Étape 1 — Violation A2.

`(idemplacement, geo_longitude, geo_latitude)` → `arrondissement, complementa`

Le déterminant n'est pas super-clé. On décompose :

R_1 = **Emplacement**`(idemplacement, geo_longitude, geo_latitude, arrondissement, complementadresse, adresse)`
Clé : `(idemplacement, geo_longitude, geo_latitude)`

Étape 2 — Violation A3 dans R_2.

`(genre, espece)` → `libellefrancais`

Le déterminant n'est pas super-clé. On décompose :

R_3 = **Encyclopedie**`(genre, espece, libellefrancais)`
Clé : `(genre, espece)`

R_4 = **Arbre**`(idbase, typeemplacement, domanialite, idemplacement, geo_longitude, geo_latitude, genre, espece, varieteoucultivar, circonferenceencm, hauteurenm, stadedeveloppement, remarquable)`
Clé : `idbase`

Résultat : 3 tables, toutes en FNBC.

5.2. Dataset Espaces Verts — Cas intéressants

Cas 1 — Extraction des coordonnées géométriques. La DF EV5 implique une clé composite `(id_geom, ordre)`. On isole :

Geom_coordonnee`(id_geom, ordre, longitude, latitude)`
Clé : `(id_geom, ordre)`

Cas 2 — Extraction de l'historique ENB. `ida3d_enb` n'est pas l'identifiant de l'espace vert : un même dossier ENB peut regrouper plusieurs espaces verts. Isoler ces attributs évite leur répétition et constitue une violation FNBC.

Historique(ida3d_enb, annee_ouverture, annee_renovation, ancien_nom_ev, annee_changement_nom, nb_entites, ouvert_ferme, url_plan, last_edited_user, last_edited_date)
Clé : ida3d_enb

Cas 3 — Extraction de l'équipement technique. id_eqpt détermine id_division et competence, mais pas site_villes ni id_atelier_horticole (violations massives détectées). Ces deux derniers attributs restent dans Espace_vert.

Admi(id_eqpt, id_division, competence)
Clé : id_eqpt

Cas 4 — Atomisation et extraction de la géométrie. id_geom détermine les mesures géométriques. Un changement de surface implique un changement de géométrie.

Geom_mesures(id_geom, geom_type, poly_area, surface_totale_reelle, surface_horticole, presence_cloture, perimeter)
Clé : id_geom

Espace_vert(nsq_espace_vert, nom_ev, type_ev, categorie, adresse_numero, adresse_complement, adresse_typevoie, adresse_libellevoie, adresse_codepostal, geo_latitude_ev, geo_longitude_ev, site_villes, id_atelier_horticole, id_eqpt, ida3d_enb, id_geom)
Clé : nsq_espace_vert

Résultat : 5 tables, toutes en FNBC.

6. Tables de la décomposition — Clés et DFs locales

6.1. Dataset Arbres

Table	Description
Encyclopedie	**Attributs :** genre, espece, libellefrancais **Clé candidate :** (genre, espece) **DF locale :** (genre, espece) → libellefrancais

Table	Description
Emplacement	**Attributs :** `idemplacement, geo_longitude, geo_latitude, arrondissement, complementadresse, adresse` **Clé candidate :** `(idemplacement, geo_longitude, geo_latitude)` **DF locale :** clé → `arrondissement, complementadresse, adresse`
Arbre	**Attributs :** `idbase, typeemplacement, domanialite, idemplacement, geo_longitude, geo_latitude, genre, espece, varieteoucultivar, circonferenceencm, hauteurenm, stadedeveloppement, remarquable` **Clé candidate :** `idbase` **DF locale :** `idbase` → tous les autres attributs **FK :** `(genre, espece)` → Encyclopedie **FK :** `(idemplacement, lon, lat)` → Emplacement

6.2. Dataset Espaces Verts

Table	Description
Admi	**Attributs :** `id_eqpt, id_division, competence` **Clé candidate :** `id_eqpt` **DF locale :** `id_eqpt` → `id_division, competence`
Historique	**Attributs :** `ida3d_enb, annee_ouverture, annee_renovation, ancien_nom_ev, annee_changement_nom, nb_entites, ouvert_ferme, url_plan, last_edited_user, last_edited_date` **Clé candidate :** `ida3d_enb` **DF locale :** `ida3d_enb` → tous les autres attributs
Geom_mesures	**Attributs :** `id_geom, geom_type, poly_area, surface_totale_reelle, surface_horticole, presence_cloture, perimeter` **Clé candidate :** `id_geom` (SERIAL — justifié par atomisation)

Table	Description
	DF locale : `id_geom` → tous les autres attributs
Espace_vert	**Attributs :** `nsq_espace_vert, nom_ev, type_ev, categorie, adresse_numero, adresse_complement, adresse_typevoie, adresse_libellevoie, adresse_codepostal, geo_latitude_ev, geo_longitude_ev, site_villes, id_atelier_horticole, id_eqpt, ida3d_enb, id_geom` **Clé candidate :** `nsq_espace_vert` **DF locale :** `nsq_espace_vert` → tous les autres attributs **FK :** `id_eqpt` → Admi **FK :** `ida3d_enb` → Historique **FK :** `id_geom` → Geom_mesures
Geom_coordonnee	**Attributs :** `id_geom, ordre, longitude, latitude` **Clé candidate :** `(id_geom, ordre)` **DF locale :** `(id_geom, ordre)` → `longitude, latitude`

7. Anomalies détectées dans les données

7.1. Dataset Arbres

Anomalies — Arbres

AN1 — Doublons sur `idbase` (3 cas) Les `idbase` 125874, 137806 et 109234 apparaissent deux fois avec des données différentes. Probablement une double saisie lors d'une migration de données.

AN2 — Ambiguïté des noms (16 paires) 16 couples (genre, espèce) ont plusieurs libellés français. Exemple : *Prunus avium* → « Cerisier à fleurs » / « Cerisier à fruits » / « Merisier ».

AN3 — Codes `idemplacement` génériques Les codes `00000001` à `00000099` sont des valeurs par défaut sans signification géographique.

AN4 — Stade de développement composite Certaines valeurs contiennent des chaînes concaténées sans séparateur, ex. : « Jeune (arbre)Adulte ». Mises à

NULL à l'import.

AN5 — 4 754 arbres sans taxon 4 754 arbres ont `genre` ou `espece` NULL. Ils ne peuvent pas être rattachés à `Encyclopedie`.

7.2. Dataset Espaces Verts

Anomalies — Espaces Verts

AN6 — Violations sur `ida3d_enb` (4 cas) Les dossiers ENB `JDE8344`, `70710`, `JDE6224` et `JDE16193` sont partagés entre plusieurs espaces verts avec des valeurs contradictoires.

AN7 — Valeurs « poubelle » sur `id_eqpt` et `ida3d_enb` La valeur «0» est utilisée comme valeur par défaut sans signification. Remplacée par NULL à l'import.

AN8 — 2 espaces verts sans géométrie 2 lignes n'ont pas de `Geo Shape`. Importées avec `id_geom = NULL`.

AN9 — Valeurs de `competence` non standards Certaines lignes ont `competence = '0'` ou vide. Filtrées à l'import.

8. Requêtes de reconstruction des données initiales

8.1. Reconstruction des arbres

cf(fichier verification.sql)

9. Couverture minimale

La couverture minimale est obtenue en appliquant les trois étapes suivantes sur l'ensemble des DFs identifiées :

1. **Décomposition des parties droites** : chaque DF n'a qu'un seul attribut en partie droite.
2. **Suppression des attributs redondants à gauche** : on vérifie que chaque attribut de la partie gauche est nécessaire.
3. **Suppression des DFs redondantes** : on vérifie qu'aucune DF ne peut être déduite des autres.

9.1. Dataset Arbres

Ensemble de départ : $\mathcal{F}_{\text{arbres}} = \{ A_1,\ A_2,\ A_3 \}$

Étape 1 — Parties droites déjà atomiques après décomposition.

Étape 2 — Aucun attribut redondant dans les parties gauches :

- A_1 : `idbase` est un seul attribut.
- A_2 : retirer `idemplacement`, `geo_longitude` ou `geo_latitude` de la partie gauche ne permet plus de déterminer `arrondissement` (le contre-exemple est dans `verification_df.sql`).
- A_3 : retirer `genre` ou `espece` ne suffit plus — un genre seul comme `Prunus` est associé à plusieurs libellés.

Étape 3 — Aucune DF redondante :

- A_1 ne peut pas être déduite de A_2 et A_3.
- A_2 ne peut pas être déduite de A_1 et A_3 (`idemplacement` n'est pas une super-clé).
- A_3 ne peut pas être déduite de A_1 et A_2 (`genre`, `espece` ne sont pas déterminés par `idemplacement`).

Couverture minimale :

$$\mathcal{F}^{c}_{\text{arbres}} = \{ A_1,\ A_2,\ A_3 \} \quad \text{(inchangée)}$$

Le graphe correspondant est fourni dans `graphviz/couverture_minimale_arbres.pdf`.

9.2. Dataset Espaces Verts

Ensemble de départ : $\mathcal{F}_{\text{ev}} = \{ EV_1,\ EV_2,\ EV_3,\ EV_4,\ EV_5 \}$

Étape 1 — Parties droites déjà atomiques après décomposition.

Étape 2 — Aucun attribut redondant dans les parties gauches :

- EV_1, EV_2, EV_3, EV_4 : parties gauches à un seul attribut.
- EV_5 : retirer `id_geom` ou `ordre` ne permet plus de déterminer les coordonnées — un `id_geom` est associé à plusieurs points, un `ordre` seul n'a pas de sens.

Étape 3 — Aucune DF redondante :

- EV_2 n'est pas déductible des autres (`ida3d_enb` n'est pas une clé).
- EV_3 n'est pas déductible des autres (`id_eqpt` n'est pas une clé).
- EV_4 n'est pas déductible des autres (`id_geom` n'est pas une clé).
- EV_5 n'est pas déductible des autres (clé composite unique).

Couverture minimale :

$$\mathcal{F}_{\text{ev}}^{c} = \{\, EV_1,\, EV_2,\, EV_3,\, EV_4,\, EV_5 \,\} \quad \text{(inchangée)}$$

Le graphe correspondant est fourni dans `graphviz/couverture_minimale_ev.pdf`.